BUSINESS INTELLIGENCE AGENT

Relatório técnico do projeto

Arquitetura, validação funcional, recuperação RAG, verificação factual e avaliação ao vivo com Qwen3

Data de referência	08 de novembro de 2026
Modelo generativo	qwen3:1.7b via Ollama local
Observabilidade	LangSmith - projeto business-intelligence-agent
Testes automatizados	164 aprovados; 8 avisos de dependências
Avaliação live	6 de 6 cenários com veredito SUSTENTADA

Síntese executiva

O Business Intelligence Agent integra fontes estruturadas e documentais para responder perguntas de negócio. A execução integrada utiliza Qwen3 local com chamadas reais a ferramentas, SQL somente leitura, recuperação RAG, memória e uma camada de verificação NLI. Na validação final de 08/11/2026, os seis cenários controlados da avaliação ao vivo foram classificados como sustentados, e a suíte automatizada registrou 164 testes aprovados.

Resultado central: a rota conceitual sobre receita líquida e campos físicos foi refinada para decompor fórmulas em afirmações atômicas, selecionar trechos documentais específicos e solicitar no máximo uma revisão do Qwen3 quando necessário. A resposta revisada é submetida novamente ao verificador; se continuar sem suporte, permanece bloqueada.

Este relatório registra resultados do ambiente e dos artefatos testados. Não constitui garantia de desempenho em produção nem substitui validação humana de domínio.

1. Objetivo e escopo

Construir um agente de Business Intelligence capaz de responder perguntas sobre vendas e regras de negócio, consultar um indicador econômico externo, preservar contexto de interações e evitar a liberação de respostas que não sejam sustentadas pelas observações das ferramentas. O projeto também explora conceitos acadêmicos de chains, agentes, estratégias de orquestração, memória e observabilidade.

A demonstração integrada principal é scripts/run_local_openai_tools_agent.py. Ela utiliza o endpoint local do Ollama (http://localhost:11434/v1), o modelo qwen3:1.7b, create_openai_tools_agent e AgentExecutor. Outras demonstrações didáticas presentes no repositório exercitam abordagens complementares.

2. Arquitetura e componentes

Orquestração: rotas determinísticas identificam perguntas quantitativas mensais, text-to-query, recordação pessoal e perguntas conceituais. Perguntas não cobertas pelas rotas especializadas são encaminhadas ao agente com ferramentas e contexto recuperado.

Dados estruturados: SQLite armazena a base de vendas de demonstração. A ferramenta sales_monthly_summary fornece agregações mensais. O text-to-query utiliza o Qwen3 para propor um plano estruturado a partir de um catálogo fechado; o backend valida identificadores e compila SQL parametrizado, somente leitura.

Conhecimento documental: documentos Markdown em data/knowledge_base/ incluem glossário de KPIs, dicionário de dados, regras de negócio e fontes/limitações. Embeddings multilíngues e FAISS permitem buscar trechos relevantes; a expansão de consultas reduz diferenças de vocabulário.

API externa: a ferramenta get_selic_target consulta a série SGS 432 do Banco Central do Brasil. A avaliação final registrou a observação de 13,75% a.a. datada de 08/11/2026.

Memória: a memória conversacional mantém até oito mensagens anteriores em RAM na demonstração integrada. A memória de longo prazo é persistida em SQLite, organizada em categorias semântica, episódica e procedural, e recuperada por busca híbrida lexical/semântica com FAISS e Reciprocal Rank Fusion.

Verificação: o modelo mDeBERTa multilíngue de NLI compara afirmações com evidências. A aplicação também aplica verificações numéricas e de coerência, retornando SUSTENTADA, REFUTADA, INCONCLUSIVA ou INCOERENTE. Os escores não são probabilidades calibradas.

3. Avaliação de recuperação RAG

O benchmark de recuperação reutilizou o índice FAISS existente e comparou busca original, expandida e híbrida em 14 perguntas, com top-k=4. A relevância foi marcada manualmente por documento/fonte; chunks repetidos da mesma fonte foram contados uma vez.

Estratégia	Precision@4	Recall@4	MRR
Original	0,4643	0,9762	0,9643
Expandida	0,4821	1,0000	1,0000
Híbrida	0,4821	1,0000	1,0000

Em relação à busca original, a estratégia híbrida acrescentou 1,79 p.p. em Precision@4, 2,38 p.p. em Recall@4 e 3,57 p.p. em MRR. A estratégia expandida e a híbrida empataram neste benchmark. Os resultados indicam ganho concentrado em consultas com incompatibilidade vocabular, não melhoria universal. Essas métricas medem recuperação de fontes, não correção das respostas.

4. Avaliação ao vivo com Qwen3 e LangSmith

A avaliação final foi executada em 08/11/2026 com o modelo local qwen3:1.7b, tracing ativo e execução sequencial. O dataset business-intelligence-agent-qwen3-live-v1 contém seis cenários cobrindo SQL mensal, text-to-query, API externa, memória multi-turn, RAG conceitual e consulta multi-source.

Cenário	Ferramenta(s)	Veredito
monthly_sql	sales_monthly_summary	SUSTENTADA
text_to_query	text_to_query_sales	SUSTENTADA
external_api	get_selic_target	SUSTENTADA
multi_turn_memory	sales_monthly_summary (2 chamadas)	SUSTENTADA
rag_conceptual	business_knowledge_search	SUSTENTADA
multi_source	SQL + RAG	SUSTENTADA

Resultado agregado: 6/6 cenários com veredito SUSTENTADA.

Exemplos quantitativos validados: receita líquida de setembro/2026 de R$ 25.250,00; receita bruta de R$ 26.650,00; top categorias por receita líquida de R$ 18.335,00, R$ 4.410,00 e R$ 2.505,00. A memória multi-turn respondeu ao follow-up sobre o mesmo período. A consulta à API retornou Selic de 13,75% a.a. na observação registrada para 08/11/2026.

5. Validação detalhada do RAG conceitual

O cenário conceitual final produziu sete afirmações atômicas. Todas foram classificadas como APOIA pelo NLI, com evidência selecionada do dicionário de dados ou do glossário.

Afirmação	Entailment	Veredito
Receita bruta por item: quantity × unit_price	98,97%	APOIA
Desconto por item: quantity × unit_price × discount_pct	99,56%	APOIA
Receita líquida por item: quantity × unit_price × (1 - discount_pct)	82,57%	APOIA
Definição de quantity	98,19%	APOIA
Definição de unit_price	94,82%	APOIA
Definição de discount_pct	97,61%	APOIA
Receita líquida = receita bruta - descontos	82,08%	APOIA

Durante o refinamento, o verificador passou a separar afirmações compostas, priorizar fórmulas documentadas sobre definições isoladas de campo e converter expressões matemáticas isoladas em hipóteses em linguagem natural antes da classificação. Marcadores de listas numeradas também são removidos da extração de claims. Na rota conceitual específica, uma tentativa de revisão orientada pelo resultado NLI pode ser solicitada; a nova resposta é submetida novamente à verificação.

6. Testes automatizados

A execução final registrada em 08/11/2026 reportou 164 testes aprovados e oito avisos de depreciação/futuro de dependências. Nenhum teste falhou. A bateria inclui regressões para preservação de identificadores snake_case, seleção de evidências de campo e fórmula, decomposição de explicações compostas, normalização de equações e remoção de marcadores de listas numeradas.

Comando para reproduzir a suíte:

pytest -q

Os avisos incluem interfaces clássicas do LangChain que estão depreciadas e um aviso de futuro do PyTorch. Eles não bloquearam a execução, mas devem ser considerados em uma futura atualização de dependências.

7. Observabilidade e artefatos

Projeto LangSmith: business-intelligence-agent. Dataset: business-intelligence-agent-qwen3-live-v1. Experimento final: qwen3-live-agent-evaluation-37b531b2. A execução foi sequencial e o tracing estava ativo. O JSON local correspondente está em outputs/qwen3_live_evaluation.json.

Link do experimento: https://smith.langchain.com/o/647ba4a7-e48d-499d-8d39-36bbf1042aeb/datasets/89d20358-ec83-4d57-91ad-e61482a5111a/compare?selectedSessions=b05e999c-94c3-40d1-bbb1-e626c6eea974

8. Limitações e interpretação

A avaliação ao vivo contém seis cenários curados, não uma amostra abrangente de perguntas em produção. O resultado é específico ao modelo qwen3:1.7b, às instruções, ferramentas, dataset e hardware utilizados. A avaliação multi-turn cobre dois turnos e não testa a persistência do histórico conversacional em RAM após reinicialização.

O benchmark de recuperação tem 14 perguntas e fontes esperadas definidas manualmente. Precision@4, Recall@4 e MRR avaliam recuperação documental, não a correção das respostas finais. Os escores NLI não são probabilidades calibradas e podem errar; o verificador é uma camada adicional de controle, não uma garantia absoluta. A API externa pode mudar com o tempo; os valores citados são os registrados no artefato da execução de 08/11/2026.

9. Reprodução e arquivos de evidência

Avaliação ao vivo: python scripts/evaluate_live_qwen_agent.py. Suíte de testes: pytest -q. Benchmark de recuperação: python scripts/evaluate_rag_retrieval.py. O benchmark RAG reutiliza o índice FAISS persistido. Artefatos: outputs/qwen3_live_evaluation.json, docs/AVALIACAO_AGENTE_QWEN3.md, docs/EVIDENCIAS_LANGSMITH.md e docs/AVALIACAO_RAG.md.

Etapa separada: a gravação do vídeo demonstrativo permanece planejada para a próxima sessão de trabalho.

Fim do relatório técnico